Tesina - Image Processing and Computer vision

Ricostruzione 3D Interattiva di Ambienti con Oggetti Selezionabili

Studenti: Alice Buccoleri (s358621), Daniele Bongiovanni (s358622)

Docenti di riferimento: Prof. Bartolomeo Montrucchio , Prof.ssa Roberta Macaluso

Introduzione e Obiettivi del Progetto

La presente tesina mira alla realizzazione di un **sistema** capace di ricostruire un ambiente tridimensionale a partire da immagini o video. La ricostruzione, rappresentata come nuvola di punti o mesh texturizzata, sarà successivamente integrata con tecniche di *Computer Vision* per individuare oggetti di interesse nelle immagini di partenza.

L'**obiettivo finale** è associare a ciascun oggetto una maschera o una regione selezionabile e rendere possibile una semplice interazione nella scena ricostruita, ad esempio l'evidenziazione, lo spostamento o la rotazione dell'oggetto.

Analisi Comparativa dei Software di Ricostruzione

Nella fase preliminare del lavoro sono stati analizzati alcuni degli strumenti più rilevanti nel panorama della ricostruzione 3D da immagini, video o dati LiDAR.

La maggior parte di essi utilizza la **fotogrammetria**, una tecnica che permette di stimare la geometria di una scena a partire da fotografie sovrapposte.
In genere, il processo prevede l'individuazione di punti caratteristici nelle immagini, il confronto tra essi in fotografie differenti e la stima della posizione delle camere.
Da queste informazioni viene inizialmente generata una **nuvola di punti sparsa**; in seguito, attraverso tecniche di *Multi-View Stereo*, si ottiene una nuvola più densa e infine una **mesh 3D con texture**.

Acquisizione del dataset

Per la sperimentazione è stato creato un dataset relativo ad una stanza.
Esso è composto da **481 fotografie** e **due video**, acquisiti con un iPhone 13, con l'obiettivo di ottenere un'adeguata copertura dell'ambiente da più punti di vista.
Le **fotografie** sono state scattate seguendo il perimetro della stanza a tre diverse altezze: circa all'altezza dei piedi, del busto e della testa.
Questa scelta permette di inquadrare sia gli elementi posti nella parte inferiore dell'ambiente, come pavimento, mobili bassi e oggetti appoggiati, sia gli elementi presenti ad altezze maggiori, come pareti, finestre, poster e soffitto.
È stata inoltre realizzata una sequenza di immagini a 360° dal centro della stanza, utile per

integrare le informazioni acquisite lungo il perimetro e riprendere le parti più centrali dell'ambiente.
Sono stati acquisiti anche due **video**, effettuando movimenti lenti e continui della videocamera. Lo scopo è ottenere frame consecutivi con un'elevata sovrapposizione visiva.

Per gli strumenti in cui è possibile sfruttare il sensore **LiDAR** del dispositivo mobile (nel nostro caso un iPhone 17 Pro), l'acquisizione è stata eseguita direttamente tramite scansione della stanza con lo smartphone.
A differenza della fotogrammetria, il LiDAR misura direttamente la distanza tra il sensore e le superfici della scena. Questo consente di ottenere una ricostruzione più rapida, anche se il dettaglio geometrico può essere inferiore poiché offre un controllo minore sulle singole fasi di ricostruzione.

Strumenti analizzati

1. COLMAP

Un software gratuito e open source molto diffuso in ambito accademico e di ricerca.
Implementa una pipeline di *Structure-from-Motion* e *Multi-View Stereo*: dapprima stima la posizione delle camere e una nuvola di punti sparsa; successivamente ricostruisce la nuvola densa e, se necessario, una mesh della scena.
COLMAP offre sia un'interfaccia grafica sia strumenti da riga di comando.
Rispetto alle applicazioni più orientate all'utente, richiede una maggiore configurazione e conoscenza tecnica, ma permette un controllo accurato delle fasi di estrazione delle feature, matching e ricostruzione.

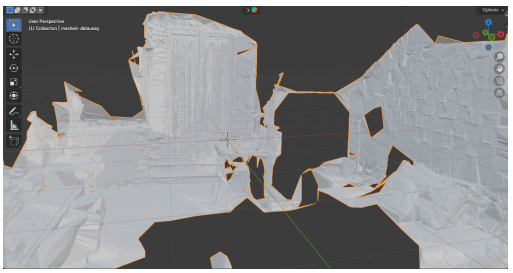
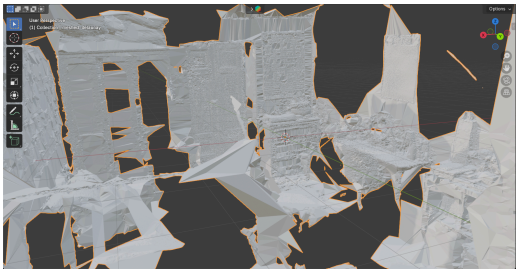

2. Agisoft Metashape

Un software professionale che permette di generare modelli 3D di buona qualità.
Supporta inoltre funzionalità avanzate come la georeferenziazione, i punti di controllo e l'integrazione di dati LiDAR.
Metashape è impiegato frequentemente in ambiti come rilievo architettonico, beni culturali, cartografia e rilievi da drone.
Rispetto alle applicazioni mobile offre un controllo molto maggiore sulla ricostruzione, ma richiede una licenza commerciale per l'utilizzo completo delle sue funzionalità.

3. AliceVision / Meshroom

AliceVision è un framework open source di Computer Vision per la ricostruzione 3D, mentre Meshroom è la sua interfaccia grafica basata su nodi.

Il programma permette di rappresentare visivamente le diverse fasi della pipeline di ricostruzione: inizializzazione delle camere, estrazione e matching delle feature, Structure-from-Motion, calcolo delle mappe di profondità, generazione della mesh e applicazione della texture.
Il principale vantaggio è la possibilità di intervenire sui singoli passaggi della pipeline e osservarne i risultati intermedi. Di contro, richiede una maggiore comprensione dei parametri e delle tecniche utilizzate, oltre a risorse hardware adeguate per elaborare dataset di immagini numerosi.

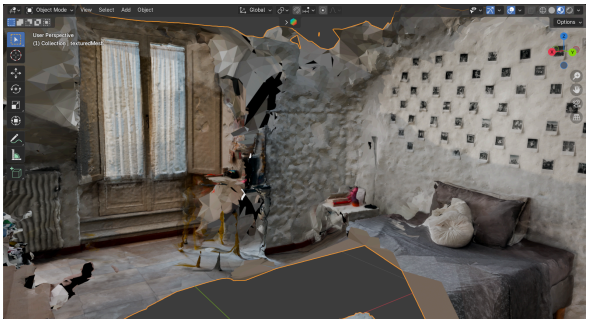

4. Pixal3D

Modello open source di intelligenza artificiale per la generazione di asset tridimensionali a partire da immagini. A differenza dei software di fotogrammetria tradizionale, utilizza un approccio basato su modelli generativi, che consente di ottenere un asset 3D anche a partire da una singola immagine.
Il modello adotta un approccio *pixel-aligned*, che mette in relazione le informazioni visive dell'immagine con la rappresentazione tridimensionale generata, stimando anche la geometria e le caratteristiche delle superfici non direttamente osservabili. È inoltre prevista una modalità *multi-view*, che permette di utilizzare più immagini dello stesso oggetto, associate ai relativi parametri di ripresa.

Il principale vantaggio consiste nella possibilità di generare rapidamente modelli tridimensionali di oggetti singoli, senza richiedere necessariamente un processo completo di ricostruzione fotogrammetrica.
Tuttavia, il modello non è specificamente progettato per la ricostruzione di ambienti interni complessi, come un'intera stanza. In questi casi, la geometria generata potrebbe non corrispondere fedelmente a quella reale, soprattutto nelle porzioni non visibili o caratterizzate da elementi sovrapposti.
Un ulteriore limite riguarda i requisiti computazionali: l'esecuzione locale si basa su TRELLIS.2, che richiede una GPU NVIDIA con almeno 24 GB di memoria video secondo la documentazione ufficiale. Tale requisito può rendere difficoltoso l'utilizzo del modello su computer personali o ambienti cloud con risorse limitate.

5. 3DF Zephyr Free

3DF Zephyr Free è la versione gratuita del software 3DF Zephyr, dedicato alla fotogrammetria. Permette di ricostruire modelli 3D a partire da fotografie o da frame estratti da un video, generando nuvole di punti, mesh e texture.
La versione gratuita è pensata per progetti personali e per l’apprendimento della

fotogrammetria. Presenta però alcune limitazioni, tra cui il numero massimo di 50 immagini o frame utilizzabili in un progetto. Nonostante questo limite, può essere adatta alla ricostruzione di un oggetto o di una piccola scena.

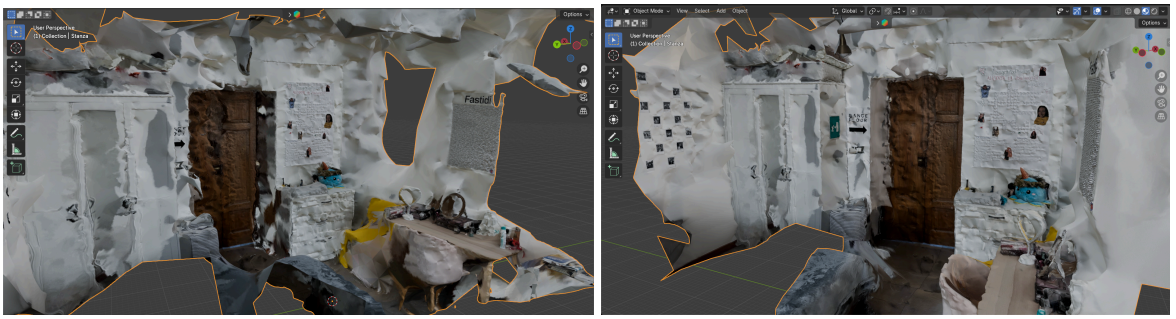

6. RealityScan

Soluzione di fotogrammetria orientata alla creazione di modelli 3D fotorealistici e nuvole di punti a partire da fotografie e scansioni laser. Può essere utilizzata per oggetti singoli, ambienti interni o scene più estese e include strumenti per la pulizia, l'ottimizzazione e l'esportazione del modello.
È disponibile anche una versione mobile che guida l'utente durante l'acquisizione, fornendo indicazioni sulle parti della scena già fotografate. RealityScan è quindi una soluzione pratica per ottenere rapidamente un modello 3D, pur offrendo meno visibilità sui dettagli algoritmici rispetto agli strumenti open source.

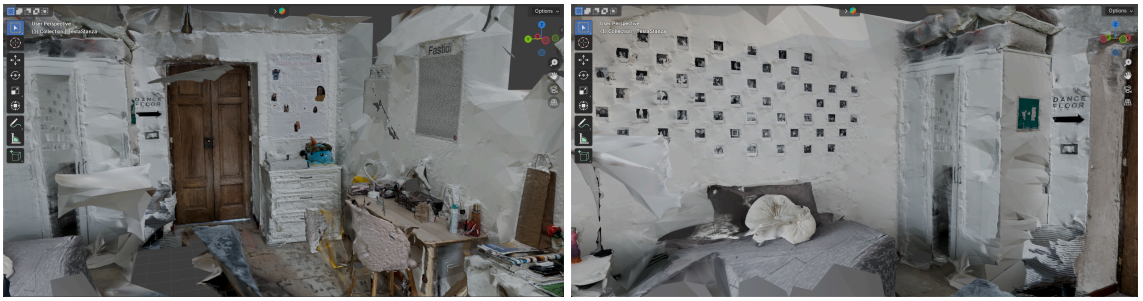

7. Scaniverse

Applicazione mobile per la scansione 3D di oggetti e ambienti. Utilizza le immagini della fotocamera e, nei dispositivi che ne dispongono, i dati di profondità del sensore LiDAR. Durante la scansione fornisce un feedback visivo sulla copertura della scena, aiutando l'utente a individuare le zone non ancora acquisite.
L'applicazione può produrre mesh 3D e rappresentazioni basate su Gaussian Splatting, una tecnica recente pensata soprattutto per la visualizzazione fotorealistica di una scena da diversi punti di vista. Scaniverse è quindi una soluzione rapida e accessibile per sperimentare la cattura tridimensionale con smartphone.

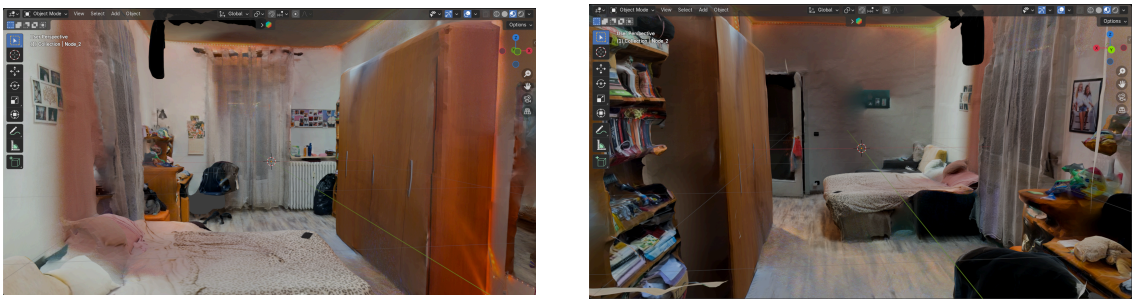

8. Polycam

Applicazione per smartphone e tablet che permette di acquisire modelli 3D di oggetti e ambienti. Supporta sia la fotogrammetria basata su fotografie, sia l'acquisizione tramite LiDAR nei dispositivi compatibili.
La modalità LiDAR è utile per ricostruire rapidamente stanze e piccoli ambienti, poiché restituisce direttamente una geometria approssimata della scena. La modalità fotografica, invece, può fornire dettagli visivi maggiori, ma richiede immagini ben sovrapposte e tempi di elaborazione più lunghi. Polycam è particolarmente interessante per il progetto perché consente di acquisire facilmente una scena reale senza utilizzare una fotocamera professionale.

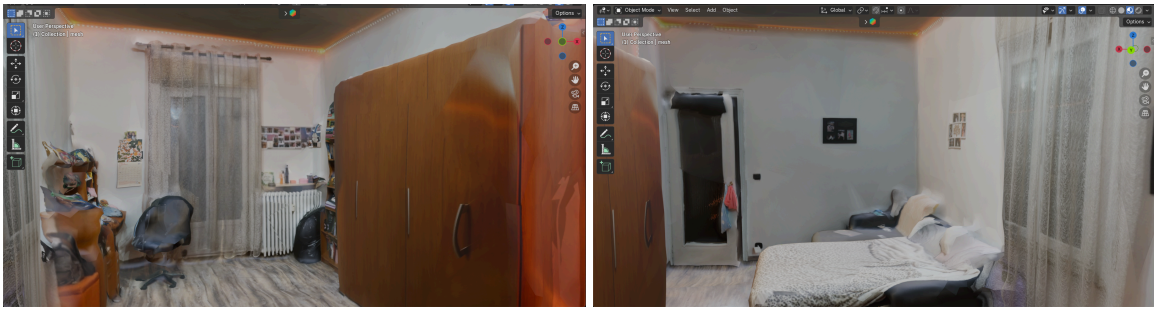

Scelta dello strumento e risultati della ricostruzione 3D

Dopo aver analizzato e sperimentato diversi strumenti per la ricostruzione 3D, abbiamo scelto di utilizzare **Polycam**, che ha fornito uno dei risultati più soddisfacenti in termini di completezza della scena, qualità visiva e riconoscibilità degli elementi presenti nell'ambiente.

Rispetto agli altri strumenti utilizzati, è emersa una differenza significativa nella qualità delle ricostruzioni ottenute. I modelli generati presentano diverse irregolarità geometriche, superfici frammentate e deformazioni evidenti, soprattutto in corrispondenza degli arredi e delle zone più complesse della stanza.
Polycam, invece, ha permesso di ottenere una rappresentazione più continua e coerente dell'ambiente, preservando meglio la disposizione spaziale degli oggetti e la struttura generale della scena.

Queste differenze possono essere ricondotte anche alle diverse tecniche di acquisizione: mentre la fotogrammetria ricostruisce la geometria attraverso l'individuazione di corrispondenze tra immagini, il LiDAR acquisisce direttamente informazioni sulla profondità della scena, facilitando la ricostruzione delle superfici anche in presenza di zone poco caratterizzate da dettagli visivi.

Nonostante siano comunque presenti alcune imperfezioni geometriche e una perdita di dettaglio nelle superfici più complesse, il risultato risulta complessivamente adeguato agli obiettivi del progetto.

Segmentazione degli oggetti mediante tecniche di Computer Vision

Strumento utilizzato: Segment Anything Model 2

Per l'identificazione degli oggetti presenti nelle immagini utilizzate per la ricostruzione tridimensionale, abbiamo scelto di utilizzare **Segment Anything Model 2 (SAM 2)**, un modello di segmentazione sviluppato da Meta.

SAM 2 permette di individuare e isolare oggetti all'interno di immagini attraverso un approccio di *prompt-based segmentation,* nel quale l'utente fornisce indicazioni al modello mediante punti o regioni di interesse.

In particolare, il modello consente di utilizzare:

- **Punti positivi**, per indicare le parti dell'immagine appartenenti all'oggetto da segmentare.
- **Punti negativi**, per escludere regioni erroneamente associate all'oggetto.

L'output consiste in una **maschera binaria**, nella quale i pixel appartenenti all'oggetto selezionato assumono valore 1 (bianco), mentre quelli dello sfondo assumono valore 0 (nero).

Implementazione

Per il progetto è stata utilizzata la versione **SAM 2.1 Hiera Tiny**, scelta per il ridotto costo computazionale rispetto a varianti più grandi del modello.

L'implementazione è stata realizzata in **Python**, utilizzando PyTorch per l'esecuzione del modello e OpenCV per la gestione delle immagini e dell'interazione con il mouse.
Il programma sviluppato permette di caricare un'immagine RGB del dataset, selezionare uno o più punti appartenenti all'oggetto e aggiungere eventuali punti negativi per correggere la selezione.
Il modello elabora quindi le indicazioni fornite e restituisce la maschera di segmentazione.
Vengono generati due output: la maschera binaria dell'oggetto e l'immagine originale con la segmentazione evidenziata mediante una sovrapposizione colorata.

https://github.com/alibucco/sam2-segmentazione-interattiva.git

Risultati sperimentali

La procedura è stata applicata a diversi oggetti presenti nella stanza, selezionati per valutare il comportamento del modello in condizioni differenti.

Segmentazione del poster

Il primo caso riguarda un poster fissato alla parete, con geometria rettangolare e contorni ben definiti.
SAM 2 ha prodotto una segmentazione soddisfacente già con un singolo click positivo, identificando quasi interamente la superficie del poster. La maschera presenta soltanto lievi irregolarità lungo uno dei bordi.

Segmentazione di un piccolo oggetto (deodorante)

Un secondo esperimento è stato condotto su un deodorante presente sulla mensola.
Il modello è riuscito a isolare una regione compatta e riconoscibile, distinguendola dagli elementi circostanti. L'esperimento mostra la possibilità di applicare SAM 2 anche a oggetti che occupano una porzione relativamente ridotta dell'immagine.

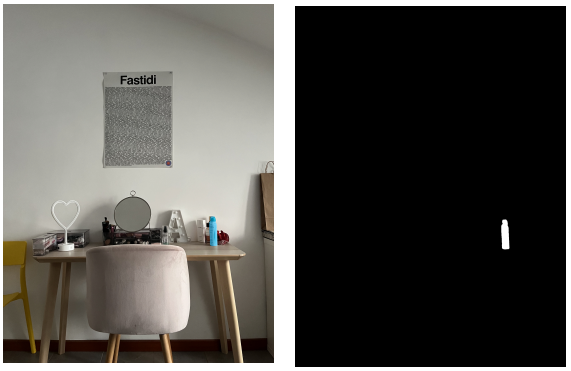

Segmentazione della sedia

Un esperimento più complesso ha riguardato una sedia, caratterizzata da una geometria articolata e da componenti con caratteristiche visive differenti.
In questo caso, un singolo click positivo sullo schienale non è stato sufficiente per ottenere una segmentazione soddisfacente dell'intero oggetto. È stato necessario aggiungere ulteriori punti positivi per includere le diverse parti della sedia.

Durante le prove, il modello ha inoltre selezionato erroneamente una porzione del battiscopa, successivamente esclusa mediante un punto negativo.
La maschera finale identifica buona parte delle superfici visibili della sedia, pur presentando alcune piccole imprecisioni.

Segmentazione in presenza di occlusioni

L'ultimo esperimento ha riguardato un oggetto parzialmente nascosto da altri elementi presenti sulla mensola.
SAM 2 ha identificato buona parte della regione visibile, ma ha incluso anche una porzione appartenente a un oggetto sovrapposto. Il risultato evidenzia una criticità della segmentazione bidimensionale: quando più oggetti si sovrappongono, i confini possono risultare ambigui e il modello può attribuire alcuni pixel all'oggetto sbagliato.

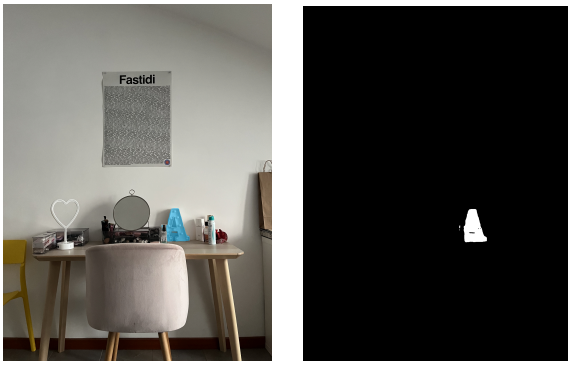

Analisi dei risultati e conclusioni

Gli esperimenti hanno mostrato come SAM 2 sia in grado di identificare oggetti di diversa forma e dimensione attraverso un numero limitato di interazioni.

I risultati migliori sono stati ottenuti con oggetti completamente visibili e caratterizzati da contorni ben definiti, come il poster, per il quale è stato sufficiente un singolo click.

Al contrario, oggetti geometricamente più complessi, come la sedia, hanno richiesto ulteriori punti positivi e negativi per migliorare la selezione.
Le principali difficoltà sono state riscontrate in presenza di occlusioni, sovrapposizioni e confini visivamente ambigui.

Nel complesso, **SAM 2 si è dimostrato uno strumento efficace per la segmentazione interattiva**, consentendo di ottenere maschere associate agli oggetti di interesse e soddisfacendo gli obiettivi richiesti dal progetto.